

Estudo comparativo entre extratores wavelet para CBIR em imagens pulmonares

Guilherme José Henrique
Departamento de Computação
Universidade Estadual de Londrina
Caixa Postal 10.011 – 86057-970
Londrina – PR – Brasil
Email: gjenrique@gmail.com

Pedro Sena Tanaka
Departamento de Computação
Universidade Estadual de Londrina
Caixa Postal 10.011 – 86057-970
Londrina – PR – Brasil
Email: pedro.stanaka@gmail.com

Resumo—Na tentativa de combater o problema do abismo semântico e o de dimensionalidade de vetores em recuperação de imagens por conteúdo, alguns pesquisadores da literatura desenvolveram aplicações utilizando as transformadas *wavelets*. O primeiro problema acontece devido a diferença entre a análise subjetiva das imagens feitas pelos humanos e a feita pelos sistemas computacionais, para resolução deste problema é utilizado a análise em multi resolução das transformadas *wavelets*. Já o problema da alta dimensionalidade, é tratado com a utilização de componentes do subespaço da transformada *wavelet*. Apesar de todos os esforços nesta área de pesquisa, as transformadas *wavelets* não tiveram propostas testadas e aplicadas em ambientes hospitalares reais. Neste trabalho, é proposto um *framework* para comparação de extratores de características. Ele suporta as operações de carga de imagens, realização de extração de características e realização de consultas em lote. Utilizando este *framework*, foram realizados testes com base médica fruto de caso de uso no HC de Ribeirão Preto. Os resultados demonstram que o uso de extratores *wavelet* são superiores à muitos extratores populares, porém, sem a aplicação de qualquer tipo de ferramenta de pré-processamento nas imagens, se mostram ineficientes para alguns tipos de cenários médicos.

I. INTRODUÇÃO

Apesar da utilização de *wavelets* para processamento de imagens não ser um tópico novo, o uso deste tipo de função em aplicações CBIR só foram introduzidas na última década. O principal uso de CBIR, ou pelo menos um dos mais relevantes dele, é na biomedicina, em que a procura por imagens utilizando somente conteúdo tem grande impacto na rotina de trabalho dos profissionais de saúde. Porém, apesar do avanço das ferramentas CBIR, ainda não há uma técnica que alcance desempenho desejado dentro de um cenário hospitalar, pois é necessário alto nível de certeza, como em um diagnóstico. Por isso, é necessário que novos métodos surjam, ou para melhorar os existentes, ou para que haja diversidade na possibilidade de soluções [1, 2, 3, 4].

Um dos grandes problemas das aplicações desenvolvidas até o presente momento é o de julgar os aspectos semânticos baseados somente em aspectos visuais, este tipo de situação pode levar a erros devido ao problema do abismo semântico entre as características extraídas em componentes de baixo-nível e conceitos abstratos que os usuários procuram em tais sistemas [5]. Nestes sistemas, sempre é utilizado algum

tipo de métrica para determinar a qualidade dos resultados alcançados, de forma geral e ampla é utilizado o espaço vetorial Euclidiano para medir as distâncias entre a imagem utilizada como entrada e as demais presentes numa base de dados, todas elas representadas por suas características em forma de um vetor n -dimensional no espaço vetorial. Porém, a quantidade de características que representam uma base de imagens deve ser escolhida com cuidado, pois a alta dimensionalidade dos vetores pode causar problemas. Outra escolha muito importante é das funções de distância para que os resultados sejam de fato significativos. Estes tipo de problemas associados a tentativa de definição de similaridade em altas dimensões é chamado maldição da “dimensionalidade”.

Alguns autores chegaram a provar que, ao aumentar o número de características, perde-se a significância de cada valor no vetor, ou seja, os elementos dos vetores passam a ser menos discriminantes [6, 7]. Por isso é tão importante estabelecer um balanceamento entre o tamanho do vetor e a discriminabilidade.

Com o objetivo de continuar pesquisas já desenvolvidas utilizando *wavelets* em CBIR e para testar a eficácia de tais métodos foi desenvolvido neste trabalho um *framework* de comparação de extratores de características que permite a carga fácil de imagens bem como a extração das características usando uma gama de extratores pré-carregados e com a funcionalidade de fácil inserção de novos extratores. Ao contrário de trabalhos como o de Silva et al. que utilizam bases médicas de exames de partes do corpo humano distintas, este trabalho tem como *baseline* o artigo de Ponciano-Silva et al., em que foram utilizados extratores baseados em histograma para a diferenciação de lesões pulmonares.

II. CONCEITOS

Na tentativa de definir relação de semelhança entre imagens, é necessário o uso de vetores de características que fazem a descrição numérica de suas características visuais. Para se calcular a dissimilaridade entre dois objetos, por exemplo imagens, é necessário o uso de funções de distância que suportem altas dimensionalidades, em que as mais utilizadas são a Manhattan e a Euclidiana.

Todos esses conceitos vão ser abordados com mais detalhes nesta seção, em que será explicado o conceito das funções *wavelets*, extração de característica e recuperação de imagens por conteúdo.

A. Wavelets

As funções ou transformadas *wavelets* separam um sinal contínuo em diferentes componentes de escalas. É comum associar cada componente de escala à uma frequência. Essa propriedade de multi resolução das *wavelets* facilita a extração de características em sinais não estacionários como imagens [10]. A análise de resolução múltipla proposta por Mallat e Meyer é utilizada neste trabalho para a extração de características visuais das imagens no banco de dados.

B. Histograma de imagem

Uma das formas mais conhecidas e mais fáceis de se extrair características de uma imagem em níveis de cinza é com o uso de histogramas. Para cada tom de cinza, é calculada a frequência em que aquele tom ocorre. Este tipo de métrica é invariante à rotação, translação e escala, o que a torna muito interessante para a análise e recuperação de imagem por conteúdo. Dois histogramas diferentes podem ser comparados pelo somatório de diferenças absolutas ou quadráticas sobre o número de pixels de cada cor [11, 12].

Devido a sua baixa complexidade computacional (linear) aliado ao fato de ser tolerante a modificações nas imagens o histograma é muito utilizado no meio acadêmico [9, 13, 12]. Dentre estes trabalhos, é importante citar o de Ponciano-Silva et al., onde a inclusão do parâmetro perceptual do médico especializado em diagnóstico por imagem é adicionado como forma de melhorar a precisão da recuperação de imagens de exames pulmonares.

C. Funções de distância

Outro ponto importante a ser abordado quando se trata de recuperação de imagens é as funções de distância, que designam a dissimilaridade entre duas imagens (ou vetores de característica). Quanto mais similares duas imagens são, tomando em conta o extrator usado, menor a distância entre elas. Alguns tipos de distâncias representativas são mostradas abaixo.

1) *Família Minkowski*: A família de funções de distância conhecida como Minkowski tem a forma geral definida como:

$$L_p((x_1, \dots, x_n), (y_1, \dots, y_n)) = \sqrt[p]{\sum_{i=1}^n |x_i - y_i|^p}$$

dentre as funções mais conhecidas desta família estão a Euclidiana (L_2), a Manhattan (L_1) e a Chebychev (L_∞).

III. TRABALHOS CORRELATOS

Apesar do fato das transformadas *wavelets* só começarem ser exploradas como ferramenta para extração de características a pouco tempo, alguns trabalhos relevantes já foram publicados nesta área. Esta seção é dedicada a apresentar algumas pesquisas que motivaram este projeto e servem como parâmetro de comparação entre as técnicas aplicadas.

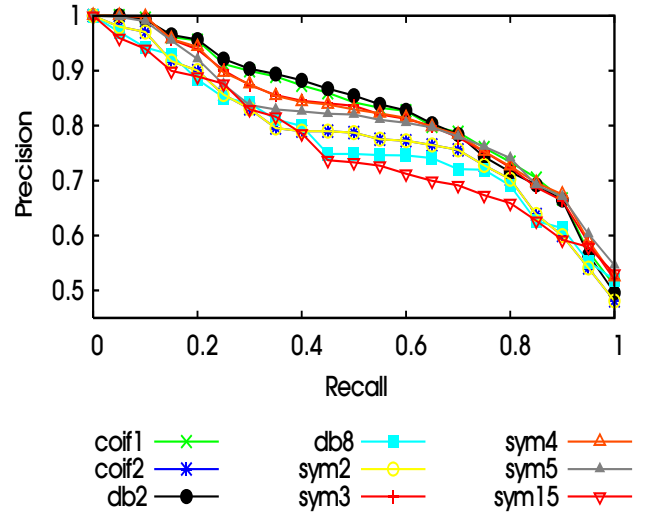


Figura 1. Resultados alcançados no artigo de Silva et al. com base de imagens de exames médicos diversos.

A. Uso de wavelets para recuperação de imagens médicas

Os primeiros trabalhos a serem publicados sobre a aplicação de wavelets em CBIR vieram no início dos anos 2000 [3]. Durante a década de 2000, muitas técnicas foram apresentadas para a recuperação de imagens através dos coeficientes da transformada *wavelet*. Estas técnicas contribuíram para que as transformadas *wavelets* pudessem ser utilizadas em aplicações como a criada para testes no trabalho de Silva et al.. Neste trabalho a autora apresenta as transformadas *wavelets* como solução ao problema da alta dimensionalidade dos vetores de característica em CBIR. A redução da dimensionalidade é devida primeiro ao fato de ser feita a análise em multi resolução e aproveitando somente o subespaço de altas frequências. Para reduzir ainda mais a dimensionalidade dos vetores de característica ainda é feito uma mineração para definir a associação estatística e retirar os elementos dos vetores que são poucos determinantes [8].

Os resultados obtidos por Silva et al., se analisados de forma geral, são satisfatórios, já que para baixos valores de recall o método obteve alto índice de acerto (precisão) chegando a casa dos 90% como pode ser visto na Figura 1. Porém, se os resultados obtidos forem analisados de uma ótica voltada para a aplicação em ambientes hospitalares, por exemplo, os resultados passam a ser não tão satisfatórios assim, pois os conjuntos de dados utilizados são incoerentes com a realidade de um hospital.

Para citar um exemplo, um dos conjuntos de dados era composto por vários exames médicos de categorias diferentes, por exemplo: ressonância magnética (RM) da pélvis, RM de cabeça, RM do abdome, entre outras. Essas imagens são muito diferentes entre si, tanto no aspecto de forma quanto na quantidade de pixels pretos na imagem, o que torna estes tipos de classes de imagens médicas fáceis de ser categorizadas. Outro fato ainda mais importante a ser analisado é que este tipo de classe de imagem não é relevante no meio hospitalar,

em que o interesse maior está no desenvolvimento de soluções que automatizem a distinção de exames do mesmo tipo, por exemplo, a diferenciação de um tipo de tumor em mamografias.

B. Inclusão de parâmetro perceptual para melhorar sistemas de CBIR

Um dos grandes desafios na recuperação de imagens por conteúdo (CBIR) é o problema do abismo de semântica, este problema ocorre pois há uma grande diferença entre o que os vetores de característica extraídos das imagens representam e o que os humanos realmente interpretam nestas imagens [14]. Entre as muitas tentativas de minimizar este problema de *gap* semântico tentou-se adicionar o parâmetro de percepção em CBIR, com este parâmetro era possível o especialista definir, qual parâmetro visual ele utiliza para julgar a dissimilaridade entre um conjunto de imagens [9].

No trabalho de Ponciano-Silva et al. é utilizado o parâmetro perceptual para aumentar a precisão na recuperação de imagens de exames médicos de pulmão. Nesse trabalho, o autor implementou variações de histograma para dar destaque entre as diferenças de brilho das imagens dos exames, toda a fase de teste foi realizada no Hospital Clínico da USP de Ribeirão Preto e com a ajuda de sete especialistas em radiologia foram analisadas 247 imagens de diferentes exames pulmonares separados em cinco classes diferentes, onde cada classe representava um tipo de lesão pulmonar [9].

Os resultados obtidos através do método proposto foram medianos se for analisado puramente a precisão em detrimento da revocação, porém, ao contrário do artigo de Silva et al., o conjunto de dados tem alta relevância no contexto médico, uma vez que são exames de mesma origem que retratam um mesmo órgão em estados diferentes.

IV. METODOLOGIA

Para facilitar a realização desse estudo comparativo, foi criado um *framework* flexível implementado em Java com base no uso dinâmico de extratores e funções de distância. Originalmente, esse framework foi utilizado na comparação entre o extrator dos subespaços de aproximação da transformada *wavelet*[8], de extratores que incluem os parâmetros perceptuais para classificar imagens do pulmão [9] e outros extratores populares implementados pela biblioteca JFeatureLib. Entretanto, sua maior aplicabilidade consiste na criação e avaliação de novos extratores de características e funções de distância de maneira fácil.

O funcionamento do sistema é composto por diversas etapas. O usuário seleciona o caminho das imagens e o sistema as persiste no banco de dados, realiza a inserção das extrações e consultas e, em seguida, permite a visualização dos resultados através de gráficos de precisão *versus* revocação. O trabalho do desenvolvedor ou pesquisador se resume na implementação dos extratores e das funções de distância. Essa série de passos é retratada na Figura 2 e será melhor detalhado nas próximas seções

Em sua implementação, foi utilizado o framework de injeção de dependências[15] Guice para gerenciamento do acoplamento entre os extratores, funções de distância e demais componentes. Para persistência dos elementos, utilizou-se o banco de dados Postgres e para manipulação das consultas, foi utilizada a biblioteca jOOQ, que produz os modelos em Java a partir do esquema do banco de dados e gera consultas com segurança de tipos, ao contrário da API padrão do Java, a *Java Database Connectivity* JDBC. Finalmente, para a implementação das transformadas *wavelets*, foi utilizado a biblioteca JWave

A. Carga de imagens

A primeira etapa do sistema consiste no carregamento inicial das imagens que farão parte das extrações de características. Em seu processo, é persistido os *bytes* da imagem, o *MIME type* e a sua classe no banco de dados. Por padrão, a classe de cada imagem está embutida no nome da imagem. Posteriormente, a manipulação dessas imagens será feita pela API nativa do Java, com exceção das imagens médicas DICOM, que são manipuladas pela biblioteca ImageJ.

B. Carga de extrações

As extrações de características das imagens são realizadas através dos extratores cadastrados no banco de dados. Eles estão presentes na tabela *extratores* que possui as seguintes colunas principais: *name* (a descrição do extrator), *class_name* (o nome da classe em Java do extrator) e a coluna *type_identifier* (parâmetros dinâmicos dos extratores). Com o uso da metaprogramação, a tupla é convertida na sua classe correspondente e é injetada no componente que realiza a carga das extrações, que tem como dependência a interface *FeatureExtractor*. Para ilustrar, os diferentes extratores disponíveis no *framework* são demonstrados na Figura 3.




Figura 3. Hierarquia dos extratores implementados no sistema para os testes

Na Tabela I, é possível observar a ligação entre as tuplas e as implementações desses extratores. Por exemplo, nos extratores relacionados ao uso da *wavelet*, o valor de *class_name* seria “ReducedScaleWaveletExtractor”, que é a classe que implementa a lógica de extração a partir da transformada *wavelet* e, nesse caso, o *type_identifier* seria o nome da classe do filtro.

Além disso, esse sistema inclui a biblioteca JFeatureLib, que conta com mais de 20 extratores. Assim, a única tarefa do desenvolvedor seria a inserção da tupla com o *class_name* JFeatureLib, que é uma classe *for framework*, recebe como parâmetro o extrator que reside na coluna *type_identifier* com o nome da classe do extrator dessa biblioteca.

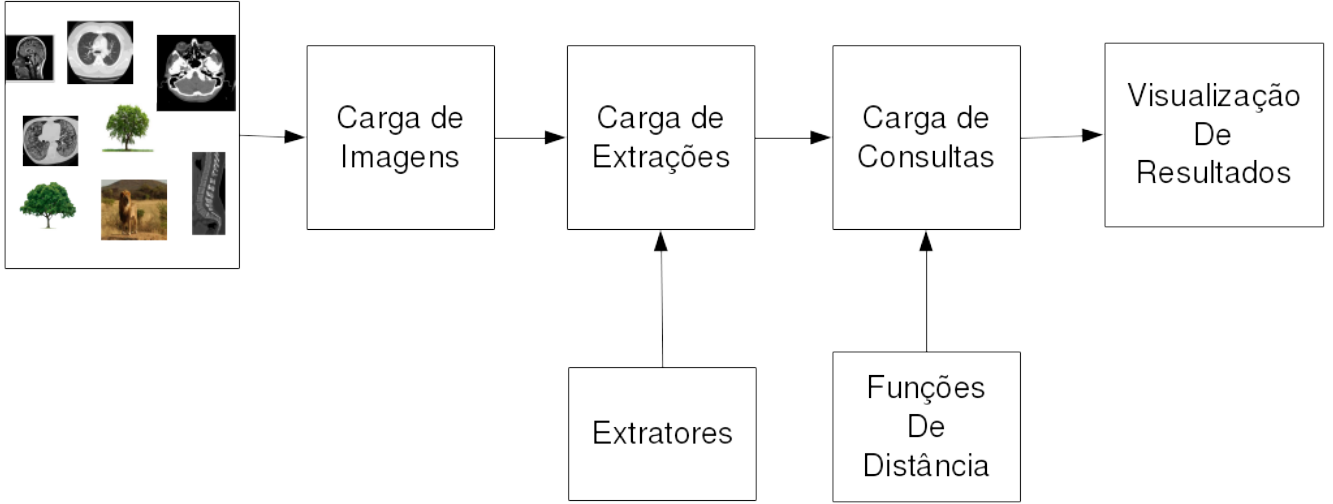


Figura 2. Passos executados pelo *framework* para avaliação da qualidade dos resultados

id	name	type_identifier	class_name	levels
100	Wavelet SubEspaco	Haar1	ReducedScaleWaveletExtractor	4
101	Wavelet SubEspaco	Haar1	ReducedScaleWaveletExtractor	5
102	Wavelet SubEspaco	Haar1	ReducedScaleWaveletExtractor	6
09	Wavelet SubEspaco	Daubechies8	ReducedScaleWaveletExtractor	4
110	Wavelet SubEspaco	Daubechies8	ReducedScaleWaveletExtractor	5
111	Wavelet SubEspaco	Daubechies8	ReducedScaleWaveletExtractor	6
17	Wavelet SubEspaco	Coiflet2	ReducedScaleWaveletExtractor	6
23	Wavelet SubEspaco	Symlets20	ReducedScaleWaveletExtractor	6
200	Textural Features	Haralick	JFeatureLib	NULL
201	Textural Features	Tamura	JFeatureLib	NULL

Tabela 1

EXEMPLO DE ALGUNS EXTRATORES NO BANCO DE DADOS

C. Carga de consultas

Para a visualização dos resultados, diversas consultas k -NNs devem ser realizadas entre as extrações existentes. Por padrão, todas as imagens são utilizadas como objeto de consulta das k -NNs, porém, se o seu conjunto de dados for grande, é aceitável escolher uma porcentagem aleatória desse conjunto para ser o objeto de consulta. O usuário também pode customizar a quantidade de consultas, decidindo o k máximo que ele deseja e os intervalos que eles serão realizados. Por exemplo, quando ele seleciona 100 como o valor máximo do k e 5 como intervalo, as consultas 5-nn, 10-nn, 15-nn até 100-nn serão realizadas.

Inicialmente, entretanto, observou-se uma grande demora para completar essas consultas. Então, para aumentar seu *throughput*, elas foram realizadas em paralelo em nível de *threads* com o uso de um *thread pool* que restringe o número de segmentos ativos.

D. Visualização de resultados

A qualidade dos resultados são avaliados com o uso de gráficos de precisão *versus* revocação [16]. A precisão é a porção dos elementos recuperados que são relevantes para a consulta, ou seja, a fração dos elementos que pertencem à mesma classe do objeto de consulta. Essa medida é dada por $Prec = \frac{|Ra|}{|A|}$, em que $|Ra|$ é o número de elementos relevantes recuperados e $|A|$ é o número de elementos do conjunto resposta da consulta. Já a revocação é a proporção de elementos relevantes no conjunto de dados que foram recuperados ao responder a consulta. Ela é dada por $Revoc = \frac{|Ra|}{|R|}$, em que $|Ra|$ é o número de elementos relevantes recuperados e $|R|$ é o número total de elementos relevantes que deveriam ser recuperados.

A partir do conjunto de consultas k -NNs realizados, a precisão é calculada pela média de todas as revocações de determinado extrator ou função de distância. O usuário pode verificar os gráficos com vários extratores a partir de uma

função de distância ou avaliar várias funções de distância a partir de um extrator. Esses gráficos são gerados pela biblioteca JavaPlot, que é uma ferramenta de ligação do GNUPlot com a linguagem Java.

V. RESULTADOS

Para verificar os resultados desse estudo comparativo entre o uso dos coeficientes de subespaço das transformadas *wavelets* e de demais extratores, vários gráficos de precisão *versus* revocação precisam ser avaliados. O *framework* apresentado na Seção IV foi utilizado para automatizar a geração desses gráficos.

Os experimentos foram realizados sobre uma base de dados de 247 imagens de pulmões realizadas no HC de Ribeirão Preto. As consultas k -NNs efetuadas com um intervalo de 5 elementos e k máximo de 100. Além disso, cada imagem desse conjunto foi o objeto de consulta e a média dessas consultas foram calculada pra representar o resultado final.

As avaliações dos resultados foram divididas em três partes: Subseção V-A examina os resultados dos gráficos de precisão *versus* revocação de diversas famílias *wavelet*. Subseção V-B apresenta as *wavelets* que tiveram melhor desempenho comparadas com extratores que utilizaram parâmetros perceptuais para classificar as imagens. Finalmente, na Subseção V-C, compara-se os resultados de *wavelets* em relação a alguns extratores renomados.

A. Comparação entre diferentes famílias de wavelets

O uso das *wavelets* é avaliado com as seguintes famílias: Haar(*db1*), Daubechies(*db8*), Coiflet(*coif1*) e Symlets(*sym2*). O uso de 4 níveis de resolução foi descartado, pois os autores demonstraram que o vetor de características continha alta dimensionalidade e concluíram que não havia vantagem em utilizar tal resolução. Por isso, serão utilizados apenas 5 ou 6 níveis nesse trabalho.

A Figura 4 mostra o gráfico para a transformada waveletet com 5 e 6 níveis de resolução com o uso da função de distância Manhattan. Já a Figura 5 mostra esses resultados para a distância Euclidiana. Visto que as imagens têm 1024X1024 pixels, os vetores de características para 5 resoluções têm 256 características e para 6 resoluções têm 64 características. Como visto no gráfico, não houve uma diferença muito grande em relação ao uso de diferentes *wavelets* para classificação de imagens pulmonares.

Os gráficos de precisão *versus* revocação das Figuras 6 e 7 correspondem aos experimentos de avaliação de diferentes funções de distância. Dentre elas, estão a L_1 , L_2 , L_∞ , Divergência de Jeffrey, Canberra e χ^2 . Como demonstrado, a melhor função de distância, independente do número de resoluções, é a Manhattan.

No artigo de Silva et al., foi possível observar uma grande discrepância no uso de diferentes *wavelets*. Porém, nesse conjunto de dados em específico, as diferenças entre as diferentes *wavelets* foram pouco visíveis. Isso ocorreu devido ao conjunto de dados daquele artigo ser constituído de imagens de partes distintas do corpo humano. Para imagens pulmonares,




Figura 4. Gráfico de precisão *versus* revocação com 5 e 6 níveis de resolução e função de distância Manhattan (L_1)




Figura 5. Gráfico de precisão *versus* revocação com 5 e 6 níveis de resolução e função de distância Euclidiana (L_2)

as classes são diferenciadas por mínimas variações em sua forma, por isso as famílias *wavelets* tiveram desempenho muito similares. Portanto, a conclusão é que não houve resultados expressivos para diferentes tipos de *wavelet* no uso em imagens pulmonares.

B. Comparação do subespaço de transformadas wavelets e métodos que incluem parâmetros perceptuais

Para verificar a eficácia no uso das *wavelets* nesse contexto, essa técnica foi comparada com os extratores propostos por Ponciano-Silva et al., que são voltados especialmente para classificação de imagens pulmonares.

Analisando os gráficos da Figura 8 e da Figura 9, é possível observar a superioridade das técnicas que fazem uso de parâmetros perceptuais. Entretanto, uma desvantagem dessas técnicas é que o processamento realizado nas imagens tem




Figura 6. Gráfico de precisão versus revocação com diferentes funções de distâncias para a *wavelet* Haar1 com 5 níveis de resolução

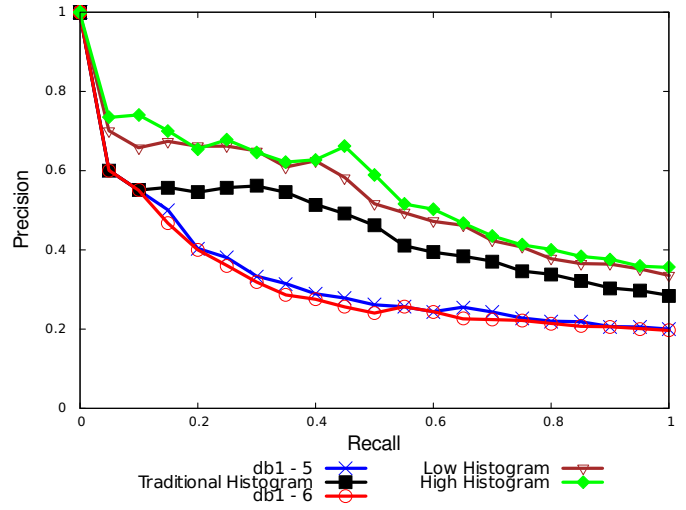


Figura 8. Gráfico de precisão versus revocação comparando a *wavelet* Haar1 com 5 e 6 níveis de resolução e o uso dos métodos com parâmetros perceptuais e função de distância euclidiana




Figura 7. Gráfico de precisão versus revocação com diferentes funções de distâncias para a *wavelet* Haar1 com 6 níveis de resolução




Figura 9. Gráfico de precisão versus revocação comparando a *wavelet* Haar1 com 5 e 6 níveis de resolução e o uso dos métodos com parâmetros perceptuais e função de distância Manhattan

utilidade somente em imagens pulmonares, enquanto o extrator baseado nos subespaços da transformada *wavelet* são genéricos e podem ser empregados em diversos gêneros de imagens.

C. Comparação com outros extratores consolidados

O teste final consiste na comparação do uso das *wavelets* com técnicas renomadas de extração de características. Entre elas, estão a Haralick [17], que tem seus descritores de características representados por uma matriz de co-ocorrência que armazena a variância, entropia, energia, entre outras características. JCD é um extrator que une os descritores do CEDD [18] e do FCTH [19] em um único histograma. Tamura [20] utiliza seis propriedade de textura da imagem, entre elas, o contraste, a regularidade e a direcionalidade. Finalmente, o extrator LuminanceLayout reduz a imagem e usa essa menor versão como um descritor. Ele tem o aspeco de ser muito

parecido com o extrator *wavelet* utilizado no trabalho, porém, ao invés de utilizar a decomposição da *wavelet*, utiliza a imagem em si.

Todos esses extratores foram implementados pela biblioteca JFeatureLib e utilizados pelo *framework* apresentado para gerar os gráficos. A Figura 10 e a Figura 11 demonstram o resultado da comparação entre esses extratores e o uso dos subespaços da transformada *wavelet* com o filtro de Haar. Todas essas técnicas apresentadas demonstraram um desempenho ruim para essa base de dados, principalmente a Haralick, e os gráficos revelam um ganho considerável do uso das *wavelets* em relação à essas técnicas populares.




Figura 10. Gráfico de precisão versus revocação da comparação entre extratores variados e da wavelet pela função de distância euclidiana




Figura 11. Gráfico de precisão versus revocação da comparação entre extratores variados e da wavelet pela função de distância Manhattan

VI. CONCLUSÃO

Neste trabalho foi proposto um *framework* flexível para a criação e comparação de extratores de características em imagens. Este sistema se mostrou muito útil para o propósito de testes de extratores já consolidados distribuídos na Internet, assim como para a avaliação dos extratores criados utilizando a biblioteca JWave.

Os primeiros testes realizados foram para comparar a eficácia entre as próprias variações de transformadas *wavelet*. Variou-se o suporte das famílias assim como o nível de resolução aplicada na extração das características. Nesses testes, obteve-se resultados insatisfatórios para a aplicação da solução em ambiente hospitalar devido aos valores médios/baixos de precisão, porém é necessário afirmar que o processamento da classe de imagens escolhida no trabalho

requeria no mínimo um pré-processamento para extração de máscara padrão, por exemplo [9].

Depois, utilizando os melhores resultados das transformadas *wavelets* foi comparado o resultado com os resultados alcançados em [9] onde é utilizado a mesma base de imagens deste trabalho. Devido ao tipo de técnica aplicada no artigo de Ponciano-Silva et al. ser específica para o tipo de dado, as *wavelets* tiveram resultados inferiores aos histogramas modificados como *High Histogram* e *Low Histogram* com o auxílio do parâmetro perceptual, porém vale reafirmar que a abordagem usando *wavelets* é genérica.

Por último, foi feito uma análise comparativa entre os extratores *wavelets* e outros extratores conhecidos entre os pesquisadores da área de CBIR, como *Haralick* e *JCD*. Neste teste o extrator que utiliza a transformada wavelet da família *Daubechies* com suporte 1, obteve melhor rendimento quando comparado todos outros extratores, pois a sua curva de Precisão vs. Revocação sempre esteve com maior área coberta.

A partir dos resultados obtidos, sobretudo nos últimos testes, é possível afirmar que, em um cenário genérico, as *wavelets* se comportam de maneira melhor que muitas das técnicas já consolidadas em CBIR, porém quando aplicada de maneira “crua” ainda é insuficiente quando comparada à técnicas especialistas.

REFERÊNCIAS

- [1] A. Traina, C. Castanon, and C. Traina, “MultiWaveMed: a system for medical image retrieval through wavelets transformations,” in *16th IEEE Symposium Computer-Based Medical Systems, 2003. Proceedings.* IEEE, 2003, pp. 150–155.
- [2] C. B. R. Ferreira and D. L. Borges, “Analysis of mammo-gram classification using a wavelet transform decomposition,” *Pattern Recognition Letters*, vol. 24, pp. 973–982, 2003.
- [3] Q. Tian, N. Sebe, E. Loupias, T. Huang, and M. Lew, “Image retrieval using wavelet-based salient points,” *Journal of Electronic Imaging*, vol. 10, no. 4, pp. 835–849, 2001.
- [4] C. Armando, B. Castañón, and U. S. P. S. a. Carlos, “Recuperação de imagens por conteúdo através de análise multiresolução por Wavelets Recuperação de imagens por conteúdo através de análise multiresolução por Wavelets,” Ph.D. dissertation, 2003.
- [5] T. M. Deserno, S. Antani, and R. Long, “Ontology of gaps in content-based image retrieval,” *Journal of digital imaging*, vol. 22, no. 2, pp. 202–215, 2009.
- [6] C. C. Aggarwal, A. Hinneburg, and D. A. Keim, *On the surprising behavior of distance metrics in high dimensional space.* Springer, 2001.
- [7] K. Beyer, J. Goldstein, R. Ramakrishnan, and U. Shaft, “When is “nearest neighbor” meaningful?” in *Database Theory—ICDT’99.* Springer, 1999, pp. 217–235.
- [8] C. W. Silva, P. H. Bugatti, M. X. Ribeiro, C. Traina, and A. J. M. Traina, “Improving CBIR using feature extraction based on wavelet transform,” in *Proceedings*

of the 14th Brazilian Symposium on Multimedia and the Web - WebMedia '08. New York, New York, USA: ACM Press, Oct. 2008, p. 51.

- [9] M. Ponciano-Silva, A. J. M. Traina, P. M. Azevedo-Marques, J. C. Felipe, and C. T. Jr., "Including the perceptual parameter to tune the retrieval ability of pulmonary cbir systems," in *CBMS*. IEEE, 2009, pp. 1–8.
- [10] E. J. Stollnitz, T. D. DeRose, and D. H. Salesin, "Wavelets for computer graphics: a primer. 1," *Computer Graphics and Applications, IEEE*, vol. 15, no. 3, pp. 76–84, 1995.
- [11] J. M. Bueno, "Suporte à recuperação de imagens médicas baseada em conteúdo através de histogramas métricos," Ph.D. dissertation, ICMC/USP, 2002.
- [12] A. J. M. Traina, "Suporte à visualização de consultas por similaridade em imagens médicas através de estrutura de indexação métrica," Ph.D. dissertation, ICMC/USP, 2001.
- [13] B. Ko, H.-S. Lee, and H. Byun, "Image retrieval using flexible image subblocks," in *Proceedings of the 2000 ACM symposium on Applied computing-Volume 2*. ACM, 2000, pp. 574–578.
- [14] A. J. Traina and J. Marques, "Fighting the semantic gap on cbir systems through new relevance feedback techniques," in *Computer-Based Medical Systems, 2006. CBMS 2006. 19th IEEE International Symposium on*. IEEE, 2006, pp. 881–886.
- [15] M. Fowler, "Inversion of control containers and the dependency injection pattern," 2004.
- [16] R. Baeza-Yates, B. Ribeiro-Neto, et al., *Modern information retrieval*. ACM press New York, 1999, vol. 463.
- [17] R. M. Haralick, K. Shanmugam, and I. H. Dinstein, "Textural features for image classification," *Systems, Man and Cybernetics, IEEE Transactions on*, no. 6, pp. 610–621, 1973.
- [18] S. A. Chatzichristofis and Y. S. Boutalis, "Cedd: color and edge directivity descriptor: a compact descriptor for image indexing and retrieval," in *Computer Vision Systems*. Springer, 2008, pp. 312–322.
- [19] —, "Fctth: Fuzzy color and texture histogram-a low level feature for accurate image retrieval," in *Image Analysis for Multimedia Interactive Services, 2008. WIA-MIS'08. Ninth International Workshop on*. IEEE, 2008, pp. 191–196.
- [20] H. Tamura, S. Mori, and T. Yamawaki, "Textural features corresponding to visual perception," *Systems, Man and Cybernetics, IEEE Transactions on*, vol. 8, no. 6, pp. 460–473, 1978.